

Lead-lag setorial na B3: existe atraso negociável?

Mimir testa se a ação mais líquida incorpora informação antes de empresas relacionadas menos líquidas.

PERGUNTA ECONÔMICA

A hipótese nasceu de uma observação simples: na natureza e na sociedade, indivíduos observam e imitam aqueles que são bem-sucedidos ou particularmente relevantes. Será que algo parecido acontece no mercado financeiro? Quando um evento afeta uma empresa líder, empresas relacionadas a ela, as seguidoras, reagem? Existe um atraso? Se esse atraso existir, é possível transformá-lo em uma oportunidade de investimento?

Condição negociável. Para virar uma estratégia, a reação das seguidoras precisaria ocorrer pelo menos no pregão seguinte, repetir-se fora da amostra e continuar positiva após os custos de negociação. Como os dados são diários, não conseguimos determinar quem reagiu primeiro dentro do mesmo pregão. Por isso, somente um efeito que permanecesse até o dia seguinte poderia ser considerado negociável.

HIPÓTESE OPERACIONAL



EXEMPLOS RECORRENTES NA REDE V1 TOP 40

GRUPO	PAR DIRECIONADO	Nº DE JANELAS
Financeiro	ITUB4 → BBDC4 / BBAS3 / ITSA4	38 / 38 / 38
Petróleo	PETR4 → PRI03 / UGPA3	20 / 26
Siderurgia	GGBR4 → CSNA3 / USIM5	35 / 30
Varejo	MGLU3 → LREN3	27

POR QUE MÍMIR?



Na mitologia nórdica, Mimir guarda o poço da sabedoria. O nome representa a estratégia, que utiliza os movimentos das ações mais líquidas como sinais antecipados das ações seguidoras, considerando que esse conhecimento só tem valor se superar os custos de negociação.


AMOSTRA E UNIDADE DE CONTAGEM

Cada observação corresponde a um par direcionado líder-seguidora em um trimestre de teste. Se o mesmo par aparece em trimestres diferentes, ele gera uma observação em cada janela. Antes de cada teste, a rede é reestimada usando apenas os 24 meses anteriores e permanece congelada durante os três meses seguintes.

CAMPO	DEFINIÇÃO
Primeira janela de treino	jan/2015 a dez/2016
Testes fora da amostra	2017-Q1 a 2026-Q2; 38 trimestres
Walk-forward	24 meses de treino → 3 meses de teste
V1 top 40	1.247 observações par × janela; 131 pares direcionados únicos
V2 top 20	452 observações par × janela; 42 pares direcionados únicos

Dados e método: um teste sem relógio inventado

O desenho reduz look-ahead e não sincronia; fator comum e falta de timestamp ainda limitam a identificação.

FONTES: FUNÇÃO E LIMITE			REGRA TEMPORAL		
FONTE	PAPEL	LIMITE	O desafio foi determinar quando cada informação se tornou pública. Fontes gratuitas raramente preservam o horário exato de publicação e o histórico de revisões. Como a CVM IPE informa apenas o dia em que o documento foi entregue, todo documento datado em D foi considerado conhecido somente na primeira abertura da B3 após D. Essa regra pode perder parte da reação inicial do mercado, mas evita supor um horário que não pode ser comprovado e utilizar informação futura no backtest. 		
B3 COTAHIST	Identidade, calendário, volume e PREULT.	Preço bruto; mascarar eventos corporativos.			
Yahoo	Robustez com preço ajustado.	Nunca define universo ou identidade.			
B3 + CVM/FCA	Setor histórico, ISIN e deslistados.	Validade histórica exige curadoria.			
CVM IPE	Fatos Relevantes originais da V2.	Data_Entrega não informa hora negociável.			

MODELO POR PAR E POR LAG

$$r_{F,j,t} = \alpha_{ij} + \beta_{ij}^{(k)} r_{L,i,t-k} + \varepsilon_{ij,t}$$

$r_{F,j,t}$ = retorno da seguidora j | $r_{L,i,t-k}$ = retorno da líder i defasado em k pregões

Uma regressão independente é estimada para cada $k \in \{0, 1, 2, 3\}$; $k=1$ é o teste principal. $\beta_{ij}^{(k)} > 0$ indica associação na mesma direção, não causalidade.

Retornos fechamento a fechamento: $r_t = \text{PREULT}_t / \text{PREULT}_{t-1} - 1$. Só pregões consecutivos com negociação, sem interpolação; observações que atravessam eventos corporativos são excluídas.

SELEÇÃO ANTES DO TESTE E CONTROLES			
Universo PIT	Regressão	FDR	Não sincronia
Para o universo PIT, exigimos que os ativos tenham cobertura de preços e negociação de pelo menos 95%, no mínimo 400 pregões, ISIN válido e setor vigente na data. A liquidez é calculada apenas dentro da janela de treino.	Na regressão, estimamos um OLS para cada par direcionado, incluindo intercepto e um retorno defasado da líder por vez. Usamos erros HAC(5) e exigimos um mínimo de 100 observações. Não incluímos controles de mercado, setor ou defasagens da própria seguidora.	Para controlar o FDR, aplicamos Benjamini-Hochberg a 10% sobre os p-valores bicaudais de cada janela top 40. Isso resulta em 38 famílias de 24 a 42 hipóteses, em vez de uma correção única. Apenas coeficientes β positivos ($\beta > 0$) geram sinal; a rede fica congelada.	Um dia é considerado suspeito quando tem volume zero, menos de 10 negócios, volume abaixo do P10 ou segundo fechamento consecutivo idêntico. Excluimos esse dia e o seguinte, pois são proxies de preço stale.

V1: associação contemporânea, sem atraso persistente

O teste agregado reúne 38 redes trimestrais, com seleção restrita ao treino, placebo setorial e execução fora da amostra.




FIGURA 1. Observações por par e janela. Em $k = 1$, os coeficientes ficam em $-0,0152$ na base, $-0,0170$ excluindo dias sem negociação, $-0,0157$ nos pares sempre negociados e $-0,0213$ na direção inversa. Vale ler esses números como proxies de fechamento síncrono, não como prova direta dele. Em $k = 0$, a associação pode simplesmente captar uma notícia ou um movimento comum às duas empresas. O teste de fato da hipótese aparece só nos pregões seguintes, com $k \geq 1$.

BACKTEST V1: SOMA DO P&L DIÁRIO OOS, 2017-Q1 A 2026-Q2

CARTEIRA	BRUTO	LÍQUIDO	GIRO/PREGÃO
FDR long-only	+0,15%	-1,21%	0,36%
FDR long-short	-5,64%	-8,63%	0,71%
Top-k long-only	-3,85%	-44,98%	10,81%
Top-k long-short	-4,93%	-89,55%	20,27%




FIGURA 2. 26 aprovações em 9 janelas, todas a partir de 2023. Placebo: 500 sorteios por janela (19.000); p mediano 0,632, faixa 0,320-0,910; 0/38 abaixo de 5%.

A leitura dos dados indica que as 26 aprovações se concentram a partir de 2023 e são, em sua maioria, negativas, com 15 casos em 26. Essas aprovações correspondem a apenas 12 pares únicos, e as primeiras 24 janelas não registraram nenhuma aprovação. Dessa forma, verificamos que o padrão não é persistente.

Seleção. FDR usa só $\beta > 0$. Top-k: até 20 maiores t positivos no treino, não o universo top 20.

Execução. Sinal no fechamento t ; entrada da seguidora no fechamento $t+1$; P&L de $t+2$ a $t+4$. Pesos inversamente proporcionais à volatilidade dos 60 pregões anteriores, normalizados pela exposição bruta e limitados a 10%. Posições sobrepostas recebem $1/H$ do peso-alvo. A carteira long-only elimina os shorts e renormaliza as compras.

Custos. Cada ponta carrega 13,25 bps (5 de spread, 5 de slippage e 3,25 de emolumentos). O aluguel do short fica em 5% a.a./252. PREULT sem dividendos nem JCP, e o total não é anualizado nem composto.

V2: com o classificador reprovado, o backtest é exploratório

O teste condicional tinha propósito e protocolo próprios, mas o gate impediu tratá-lo como evidência confirmatória.

STATUS INFERENCIAL

O horizonte H=3 foi definido como principal, com H=1 e H=5 para robustez, tudo pré-especificado em protocolo versionado antes da análise de P&L. O gate reprovou.

Depois da reprovação e antes da observação de qualquer P&L, uma emenda permitiu apenas a execução de um backtest estritamente exploratório. Nenhuma alteração foi feita no modelo, no prompt, no universo top 20, nos horizontes ou nos limiares.

FUNIL DE FATOS RELEVANTES

ETAPA	N
Metadados das líderes	3.280
Apresentações originais	3.085
Mapeadas / em janelas	3.071 / 2.668
Top 20 / com texto	884 / 882
Classificações válidas	795
Eventos direcionais	76
Sinais líder-dia	73

CLASSIFICADOR E USOS DE IA

O classificador Qwen3:14B rodou localmente com temperatura 0, seed 20260811 e prompt ia-eventos-1.2.5. Não foram usados preços nem P&L. A saída JSON classifica cada evento como: não específico, positivo, negativo ou neutro.

Exemplo real. PETR4 informou impacto de cerca de R\$ 350 milhões na receita. Saída: `{"especifico_empresa": true, "direcao": "negativa"}`.

Além do classificador local, os modelos Opus 5, Qwen 3.8 e GPT-5.6 apoiaram o parsing de documentos, a criação do mascote e a conferência dos cálculos. O painel cego reuniu Qwen 3.8, Kimi 2.6, Gemini 3.1 Pro e Fable5, além de uma leitura humana. Após o congelamento dos rótulos, as etapas quantitativas passaram a ser determinísticas.

AMOSTRA DE ESTRESSE POR PREVISÃO (N=90)

Amostra balanceada por previsão: 30 positivas, 30 negativas e 30 neutras. Portanto, não estima a prevalência das classes no corpus.

	Qwen3: positiva	Qwen3: negativa	Qwen3: neutra	Qwen3: não específica
Painel: positiva (n=16)	16	0	0	0
Painel: negativa (n=18)	0	18	0	0
Painel: neutra (n=56)	14	12	25	5

FIGURA 3. Contagens, não percentuais. Verde = concordância com o painel; tijolo = divergência. As linhas mostram a classe definida pelo painel. O erro mais relevante foi atribuir direção a 26 dos 56 textos neutros: 14 foram classificados como positivos e 12 como negativos.

PAINEL, GATE E FALHAS TÉCNICAS

MÉTRICA	VALOR	LEITURA
Painel de referência	4 LLMs + humano no desempate	62 unânicos entre os cinco; 19 com resultado já definido pelas LLMs; 9 empates 2-2 resolvidos pela leitura humana
Fleiss κ	0,703	convergência, não verdade nem independência
Macro-F1 com suporte	0,688	reprova <0,70
Classes com suporte	3 de 4	reprova
Recusas técnicas	87	78 por evidência não literal; 9 por reticências; truncados: 16/23; demais: 71/859

V2 exploratória: 99 operações não superam redes aleatórias

Horizonte 3 é principal; Horizonte 1 e 5 são testes de robustez pré-declarados. Promover H=1 depois do resultado seria data snooping.

RANDOMIZAÇÃO DE SEGUIDORAS




FIGURA 4. 500 redes preservam janela, líder, setor, top 20 e nº de arestas; sem self-pairs. 159/500 ≥ estratégia; $p=(159+1)/(500+1)=0,319$.

O QUE O NULO PERMITE CONCLUIR

As 99 posições resultam de 73 choques em 72 datas e não são independentes. Não foi conduzida análise de potência ou MDE, e a saída por reversão prevista no protocolo não foi implementada. O P&L mede retorno de preço, não retorno anormal. Pela ausência de horário auditável, também não estima a resposta contemporânea da líder. Com o gate reprovado, os resultados não permitem identificar difusão.

PESO, EXECUÇÃO E CUSTOS

$$u_{j,c} = \sum_{s \in c} \frac{d_s}{|F_s|}$$

$$w_{j,c} = \frac{sgn(u_{j,c}) \min(|u_{j,c}| / \sum_k |u_{k,c}|, 10\%)}{H}$$

d = direção textual | F = seguidoras
abre na 1ª abertura após D | fecha no H-ésimo pregão desde a entrada

No H=3, cada operação pesa ±3,33% e a exposição bruta máxima é 13,33%. P&L bruto +0,895%, mas entrada/saída -0,875% e aluguel -0,101% levam o líquido a -0,080%. Custos: 13,25 bps/lado e aluguel-base de 5% a.a no short.

HORIZONTES E INFERÊNCIA

H (OPERAÇÕES)	RET.	SHARPE	IC 95% BP/PREGÃO
H=1 n=100	+2,95%	+0,319	[-0,091; +0,324]
H=3 n=99 principal	-0,08%	-0,013	[-0,110; +0,106]
H=5 n=99	-0,67%	-0,142	[-0,097; +0,050]

H=3: 206 dias ativos; IC por pregão em 2.870 sessões, zeros incluídos. Bootstrap móvel: 10.000 amostras, bloco 10; Newey-West. Todos cruzam zero.

DECISÃO E APRENDIZADO

O que falhou foi a hipótese operacional, não a pesquisa. Lead-lag pode existir, mas este desenho não permitiu verificá-lo nem negociá-lo. **Decisão:** não implementar. O desenvolvimento do sinal está encerrado. Para retomar a hipótese sugerida, seriam necessários horários intradiários auditáveis, retornos ajustados por mercado e setor, e poder estatístico definido antes do teste.

